평가참여

평가 평가참여

학습단계

AI 심화 학습

학습주제

데이터 분석 (Data analysis)

미션

쇼핑몰에서 누가 자주 오고 많이 사는지 분석해서

탐험가명

김기엽

1. 학습단계 소개

AI 심화 학습 팀정보 김기엽

기술적 설명

기초 단계에서 만든 서비스에 "지능"을 입히는 단계입니다.
데이터를 분석하고, 수학적 원리를 이해하고, 모델을 직접 구현하며 AI가 어떻게 판단을 내리는지를 코드 수준에서 파악합니다.
기존 방식의 한계를 먼저 체험한 뒤, 왜 AI가 필요한지를 스스로 깨닫는 구조로 학습이 진행됩니다.
이 단계를 마치면 AI 모델의 원리를 이해할 수 있으며, 실무 데이터로 문제를 정의하고 해결할 수 있는 AI 엔지니어로 성장합니다.

개발환경

제약조건

Test case

2. 학습주제 소개

데이터 분석 (Data analysis)

기술적 설명



1. 미션 소개

데이터 분석은 AI 모델링의 출발점이다. 아무리 정교한 알고리즘도 데이터를 제대로 이해하지 못하면 의미 있는 결과를 낼 수 없다. 실제 현업 데이터는 숫자, 텍스트, 범주, 이미지 등 다양한 형태가 뒤섞여 있으며, 이를 하나의 분석 흐름으로 통합하는 능력이 AI 엔지니어의 핵심 역량이다. 이 미션은 특정 산업에 국한되지 않는 도메인 공통 역량(멀티모달 전처리, 이상치 탐지, 파이프라인 모듈화, 고객 세분화)을 기르기 위해 설계되었다. 이커머스 데이터를 예시로 사용하지만, 여기서 익히는 기술은 에너지 분야(센서 수치 + 설비 이미지 + 수요 로그), 헬스케어 분야(바이탈 수치 + 의료 영상 메타데이터 + 진료 기록) 등 어떤 도메인에서도 동일한 패턴으로 전이된다. 이 미션에서는 이커머스 플랫폼의 상품 데이터를 분석한다. 상품명(텍스트), 가격(수치), 카테고리(범주), 등록일(날짜), 상품 이미지(배열) 등 서로 다른 유형의 멀티모달 데이터를 다룬다. NumPy의 벡터 연산을 활용해 이미지 데이터를 직접 수치화하고, Pandas로 탐색적 데이터 분석(EDA)과 통계 분석을 수행하며, 시각화를 통해 비즈니스 인사이트를 도출하는 전 과정을 경험한다. 나아가 고객의 구매 패턴을 분석하는 RFM(Recency, Frequency, Monetary) 기법을 적용하여 고객을 세분화하고 비즈니스 전략을 제안하는 과정까지 수행한다. 이 경험은 이후 컴퓨터 비전, 자연어 처리, 머신러닝 미션에서 데이터 전처리와 특성 공학을 수행하기 위한 필수 기반이 된다.

이번 미션에서 반드시 수행하는 핵심 과제 3가지:

- 멀티 모달 데이터(수치 + 텍스트 + 이미지 배열)를 NumPy 벡터 연산으로 통합 처리하는 파이프라인을 Class로 구축한다.
- IQR 이상치 탐지, 그룹별 결측치 대치, 6종 시각화를 포함한 완전한 탐색적 데이터 분석(EDA)을 수행한다.
- RFM 분석으로 고객을 4개 이상 세그먼트로 분류하고, 데이터 근거에 기반한 비즈니스 전략을 제안한다.

2. 최종 결과물

다음 내용이 모두 포함된 **GitHub 레포지토리(Repository) URL**을 제출한다.

1. **데이터 분석 파이프라인 모듈** (src/pipeline.py)
    - 원본 데이터를 입력받아 전처리, 피처 엔지니어링, 요약 통계를 수행하는 Python Class 파일
    - 절차 지향 스크립트가 아닌 객체 지향(OOP) 구조로 설계
2. **분석 리포트 노트북** (notebooks/analysis_report.ipynb)
    - 전처리 결과 시각화, 통계 분석, RFM 기반 고객 세분화 결과 포함
    - 주요 분석 단계마다 마크다운 설명 작성
3. **README.md**
    - 프로젝트 개요, 데이터 설명, 비즈니스 인사이트 3가지 이상, 실행 방법

3. 과제 목표

이 과제를 마친 후, 학습자는 아래를 스스로 설명할 수 있어야 한다.

- NumPy의 벡터 연산(Vectorization)을 활용하여 반복문 없이 배열 데이터를 처리하는 방법을 설명할 수 있다.
- 이미지 데이터에서 평균, 표준편차 등 통계적 특성을 추출하여 수치형 피처로 변환하는 원리를 이해한다.
- IQR 방식을 활용한 이상치 탐지 로직을 직접 구현하고 그 원리를 설명할 수 있다.
- RFM 분석을 통해 고객을 세분화하고, 데이터 기반의 비즈니스 전략을 제안할 수 있다.
- 분석 로직을 Class로 구조화하여 재사용 가능한 코드를 설계하는 방법을 이해한다.

4. 기능 요구 사항

다음 요구사항을 모두 만족해야 한다.

1. 데이터 로드 및 기본 탐색
    - 최소 1,000건 이상, 8개 이상의 컬럼을 가진 이커머스 데이터셋을 사용한다.
    - 수치형, 범주형, 날짜형, 이미지(배열) 중 최소 3가지 이상의 데이터 유형이 포함되어야 한다.

- info() , describe() , head() 를 활용하여 데이터 구조를 파악하고 마크다운으로 해석을 작성한다.
- RFM 계산용 거래 데이터는 최소 **customer_id**, **order_date**, **amount**(또는 price*qty) 컬럼을 포함해야 한다.
- Recency 기준일은 데이터의 최종 거래일(또는 분석 기준일)로 정의한다.
- 해석은 수치 근거 1개 이상 + 시사점 1문장 이상을 포함해야 한다.

2. 분석 파이프라인 모듈화 (OOP)

- 분석 로직을 DataAnalyzer 라는 Class로 구현한다.
- 최소 다음 메서드를 포함한다: load_data() , handle_missing_values() , detect_outliers() , calculate_rfm() .
- 주요 파라미터(예: 이상치 임계값, 결측치 대치 전략)는 메서드의 인자로 받도록 설계한다.

3. 멀티 모달 데이터 피처 엔지니어링

- 이미지 데이터 : NumPy를 활용하여 각 이미지의 평균(Mean)과 표준편차(Std)를 계산하고 새로운 컬럼으로 추가한다. 반복문(for loop) 대신 배열 연산을 사용한다.
- 텍스트 데이터 : 상품명에서 단어 수(Word Count) 또는 문자열 길이를 계산하여 파생 변수로 추가한다.

4. 결측치 및 이상치 처리

- 결측치 현황을 파악하고, 그룹별(GroupBy) 통계를 활용한 대치 로직을 1가지 이상 적용한다.
- IQR 방식의 이상치 탐지 로직을 직접 함수로 구현하고, 처리 전후의 분포 변화를 시각화한다.

5. 통계 분석

- 주요 수치형 변수에 대해 평균, 중앙값, 표준편차, 사분위수를 계산하고 해석한다.
- 최소 2쌍 이상의 변수에 대해 상관계수를 계산하고 해석한다.
- 모든 해석은 수치 근거 1개 이상을 포함하고 시사점 1문장 이상을 기술한다.

6. 시각화

- 다음 6가지 유형의 차트를 각각 1개 이상 작성한다.
    - 히스토그램 : 수치형 변수의 분포

    - 박스플롯 : 이상치 처리 전후 비교
    - 막대그래프 : 범주형 변수의 빈도 또는 RFM 세그먼트별 고객 수
    - 히트맵 : 상관행렬 또는 RFM 세그먼트 분포
    - 산점도 : 두 수치형 변수의 관계
    - 라인차트 : 시계열 추세 (예: 월별 매출 추이)
  - 모든 차트에는 제목과 축 레이블을 포함한다.

7. RFM 기반 고객 세분화
   - 거래 데이터를 바탕으로 고객별 Recency, Frequency, Monetary 점수를 계산한다.
   - 고객을 최소 4개 그룹(예: VIP, Loyal, New, Churned)으로 세분화하고 각 그룹의 특징을 분석한다.
   - 세분화 결과를 바탕으로 비즈니스 관점의 인사이트를 README.md에 정리한다.

8. README.md에 작성하는 비즈니스 인사이트는 각각 다음 3가지 요소를 포함해야 한다.
   - (근거) 인사이트를 뒷받침하는 수치/그래프 1개 이상
   - (실행) 제안 액션의 대상 세그먼트 + 실행 방법 + 기대 효과
   - (검증) "추가로 필요한 데이터" 또는 "반증 가능성" 1문장

5. 보너스 과제 (선택)

1. 이미지 고급 피처 추출
   - 이미지의 히스토그램 분포나 간단한 엣지 특성을 NumPy로 직접 계산하여 피처로 추가한다.
   - 이미지 데이터의 심층적인 수치화 방법을 경험한다.

2. 코호트 분석 (Cohort Analysis)
   - 가입 월별 고객의 재구매율(Retention Rate)을 계산하고 히트맵으로 시각화한다.
   - 시간에 따른 고객 행동 변화를 추적하는 분석 기법을 경험한다.

3. 인터랙티브 시각화
   - Plotly를 활용하여 RFM 세분화 결과를 인터랙티브 차트로 시각화한다. (이 보너스에 한하여 Plotly 사용 허용)

- 동적 시각화의 장점을 경험한다.

개발환경

6. 개발 환경

- Python 3.8 이상
- 허용 라이브러리: NumPy, Pandas, Matplotlib, Seaborn
- 보너스 과제 3에 한하여 Plotly 사용을 예외적으로 허용한다.

제약조건

7. 제약 사항

금지 사항

- OpenCV, Pillow 등 이미지 처리 전용 라이브러리 사용 금지. NumPy 배열 연산으로 직접 구현한다.
- Scikit-learn, NLTK 등 머신러닝/자연어처리 라이브러리 사용 금지.
- 자동 EDA 라이브러리(pandas-profiling, sweetviz 등) 사용 금지.

이미지 처리 허용 범위 가이드

- 이미지 입력/변환 : imread() 사용 가능. 반환되는 NumPy 배열을 직접 조작한다.
- 저장/복구 : CSV에 배열이 문자열로 저장되는 경우fromstring() 또는 ast.literal_eval()로 복구한다.
- 리사이즈 : NumPy 슬라이싱(arr[::n, ::n])으로 단순 다운샘플링을 수행한다.

데이터셋

- Kaggle, AI Hub 등에서 이커머스/상품 관련 데이터를 수집하거나 제공된 샘플을 사용한다.
- 이미지 데이터는 NumPy 배열 형태로 변환하여 사용한다.
- 공개 라이선스(CC-BY, MIT 등) 데이터를 우선 사용하고, 출처를 반드시 명시한다.

Test case

8. 결과 예시

아래는 정답이 아니라 참고 예시다. 실제 문구와 구조는 달라도 된다.

- Class 구조 예시 :

```css
class DataAnalyzer:
    def __init__(self, data_path):
        self.df = None
        self.data_path = data_path

    def load_data(self):
        # 데이터 로드 로직
        pass

    def handle_missing_values(self, strategy='group_mean',
group_col=None):
        # 결측치 처리 로직
        pass

    def detect_outliers(self, column, threshold=1.5):
        # IQR 기반 이상치 탐지
        q1 = self.df[column].quantile(0.25)
        q3 = self.df[column].quantile(0.75)
        iqr = q3 - q1
        lower = q1 - threshold * iqr
        upper = q3 + threshold * iqr
        return self.df[(self.df[column] < lower) | (self.df[column] > upper)]

    def calculate_rfm(self, customer_col, date_col, amount_col):
        # RFM 점수 계산
        pass
```

- RFM 세분화 결과 예시 :

```css
| 세그먼트 | 고객 수 | 평균 구매금액 | 특징 |
|---------|--------|-------------|------|
```

```
| VIP | 120 | 450,000원 | 최근 구매, 높은 빈도, 높은 금액 |
| Loyal | 350 | 180,000원 | 꾸준한 구매, 중간 금액 |
| New | 230 | 85,000원 | 최근 첫 구매, 낮은 빈도 |
| Churned | 300 | 120,000원 | 오래전 마지막 구매, 이탈 위험 |
```

- 인사이트 예시 :

```
CSS
[인사이트 1]
(근거) Churned 그룹이 전체 고객의 30%를 차지하며, 평균 이탈 기간은 90일임.
(실행) Churned 대상 → 할인 쿠폰 발송 캠페인 → 재구매율 10% 향상 기대.
(검증) 이탈 원인(가격/품질/경쟁사)을 파악하려면 이탈 사유 설문 데이터가 추가로 필요함.

[인사이트 2]
(근거) VIP 그룹의 평균 구매 빈도는 월 4.2회로, 전체 매출의 45%를 차지함.
(실행) VIP 대상 → 전용 멤버십 혜택 강화 → 이탈 방지 전략 실행.
(검증) VIP 이탈 시 매출 감소 규모 시뮬레이션이 필요하며, 현재 데이터만으로는 정확한 LTV 산출이 어려움.
```

3. 미션 소개

쇼핑몰에서 누가 자주 오고 많이 사는지 분석해서 단골 찾기

기술적 설명



1. 미션 소개

데이터 분석은 AI 모델링의 출발점이다. 아무리 정교한 알고리즘도 데이터를 제대로 이해하지 못하면 의미 있는 결과를 낼 수 없다. 실제 현업 데이터는 숫자, 텍스트, 범주, 이미지 등 다양한 형태가 뒤섞여 있으며, 이를 하나의 분석 흐름으로 통합하는 능력이 AI 엔지니어의 핵심 역량이다. 이 미션은 특정 산업에 국한되지 않는 도메인 공통 역량(멀티모달 전처리, 이상치 탐지, 파이프라인 모듈화, 고객 세분화)을 기르기 위해 설계되었다. 이커머스 데이터를 예시로 사용하지만, 여기서 익히는 기술은 에너지 분야(센서 수치 + 설비 이미지 + 수요 로그), 헬스케어 분야(바이탈 수치 + 의료 영상 메타데이터 + 진료 기록) 등 어떤 도메인에서도 동일한 패턴으로 전이된다. 이 미션에서는 이커머스 플랫폼의 상품 데이터를 분석한다. 상품명(텍스트), 가격(수치), 카테고리(범주), 등록일(날짜), 상품 이미지(배열) 등 서로 다른 유형의 멀티모달 데이터를 다룬다. NumPy의 벡터 연산을 활용해 이미지 데이터를 직접 수치화하고, Pandas로 탐색적 데이터 분석(EDA)과 통계 분석을 수행하며, 시각화를 통해 비즈니스 인사이트를 도출하는 전 과정을 경험한다. 나아가 고객의 구매 패턴을 분석하는 RFM(Recency, Frequency, Monetary) 기법을 적용하여 고객을 세분화하고 비즈니스 전략을 제안하는 과정까지 수행한다. 이 경험은 이후 컴퓨터 비전, 자연어 처리, 머신러닝 미션에서 데이터 전처리와 특성 공학을 수행하기 위한 필수 기반이 된다.

이번 미션에서 반드시 수행하는 핵심 과제 3가지:

- 멀티 모달 데이터(수치 + 텍스트 + 이미지 배열)를 NumPy 벡터 연산으로 통합 처리하는 파이프라인을 Class로 구축한다.
- IQR 이상치 탐지, 그룹별 결측치 대치, 6종 시각화를 포함한 완전한 탐색적 데이터 분석(EDA)을 수행한다.
- RFM 분석으로 고객을 4개 이상 세그먼트로 분류하고, 데이터 근거에 기반한 비즈니스 전략을 제안한다.

2. 최종 결과물

다음 내용이 모두 포함된 **GitHub 레포지토리(Repository) URL**을 제출한다.

1. **데이터 분석 파이프라인 모듈** (src/pipeline.py)
    - 원본 데이터를 입력받아 전처리, 피처 엔지니어링, 요약 통계를 수행하는 Python Class 파일
    - 절차 지향 스크립트가 아닌 객체 지향(OOP) 구조로 설계
2. **분석 리포트 노트북** (notebooks/analysis_report.ipynb)
    - 전처리 결과 시각화, 통계 분석, RFM 기반 고객 세분화 결과 포함
    - 주요 분석 단계마다 마크다운 설명 작성

3. README.md

- 프로젝트 개요, 데이터 설명, 비즈니스 인사이트 3가지 이상, 실행 방법

3. 과제 목표

이 과제를 마친 후, 학습자는 아래를 스스로 설명할 수 있어야 한다.

- NumPy의 벡터 연산(Vectorization)을 활용하여 반복문 없이 배열 데이터를 처리하는 방법을 설명할 수 있다.
- 이미지 데이터에서 평균, 표준편차 등 통계적 특성을 추출하여 수치형 피처로 변환하는 원리를 이해한다.
- IQR 방식을 활용한 이상치 탐지 로직을 직접 구현하고 그 원리를 설명할 수 있다.
- RFM 분석을 통해 고객을 세분화하고, 데이터 기반의 비즈니스 전략을 제안할 수 있다.
- 분석 로직을 Class로 구조화하여 재사용 가능한 코드를 설계하는 방법을 이해한다.

4. 기능 요구 사항

다음 요구사항을 모두 만족해야 한다.

1. 데이터 로드 및 기본 탐색

    - 최소 1,000건 이상, 8개 이상의 컬럼을 가진 이커머스 데이터셋을 사용한다.
    - 수치형, 범주형, 날짜형, 이미지(배열) 중 최소 3가지 이상의 데이터 유형이 포함되어야 한다.
    - `info()`, `describe()`, `head()` 를 활용하여 데이터 구조를 파악하고 마크다운으로 해석을 작성한다.
    - RFM 계산용 거래 데이터는 최소 **customer_id**, **order_date**, **amount**(또는 price*qty) 컬럼을 포함해야 한다.
    - Recency 기준일은 데이터의 최종 거래일(또는 분석 기준일)로 정의한다.
    - 해석은 수치 근거 1개 이상 + 시사점 1문장 이상을 포함해야 한다.

2. 분석 파이프라인 모듈화 (OOP)

    - 분석 로직을 `DataAnalyzer` 라는 Class로 구현한다.
    - 최소 다음 메서드를 포함한다: `load_data()`, `handle_missing_values()`, `detect_outliers()`, `calculate_rfm()`.
    - 주요 파라미터(예: 이상치 임계값, 결측치 대치 전략)는 메서드의 인자로 받도록 설계한다.

3. 멀티 모달 데이터 피처 엔지니어링

- 이미지 데이터 : NumPy를 활용하여 각 이미지의 평균(Mean)과 표준편차(Std)를 계산하고 새로운 컬럼으로 추가한다. 반복문(for loop) 대신 배열 연산을 사용한다.
- 텍스트 데이터 : 상품명에서 단어 수(Word Count) 또는 문자열 길이를 계산하여 파생 변수로 추가한다.

4. 결측치 및 이상치 처리

- 결측치 현황을 파악하고, 그룹별(GroupBy) 통계를 활용한 대치 로직을 1가지 이상 적용한다.
- IQR 방식의 이상치 탐지 로직을 직접 함수로 구현하고, 처리 전후의 분포 변화를 시각화한다.

5. 통계 분석

- 주요 수치형 변수에 대해 평균, 중앙값, 표준편차, 사분위수를 계산하고 해석한다.
- 최소 2쌍 이상의 변수에 대해 상관계수를 계산하고 해석한다.
- 모든 해석은 수치 근거 1개 이상을 포함하고 시사점 1문장 이상을 기술한다.

6. 시각화

- 다음 6가지 유형의 차트를 각각 1개 이상 작성한다.
    - 히스토그램 : 수치형 변수의 분포
    - 박스플롯 : 이상치 처리 전후 비교
    - 막대그래프 : 범주형 변수의 빈도 또는 RFM 세그먼트별 고객 수
    - 히트맵 : 상관행렬 또는 RFM 세그먼트 분포
    - 산점도 : 두 수치형 변수의 관계
    - 라인차트 : 시계열 추세 (예: 월별 매출 추이)
- 모든 차트에는 제목과 축 레이블을 포함한다.

7. RFM 기반 고객 세분화

- 거래 데이터를 바탕으로 고객별 Recency, Frequency, Monetary 점수를 계산한다.
- 고객을 최소 4개 그룹(예: VIP, Loyal, New, Churned)으로 세분화하고 각 그룹의 특징을 분석한다.

- 세분화 결과를 바탕으로 비즈니스 관점의 인사이트를 README.md에 정리한다.

8. README.md에 작성하는 비즈니스 인사이트는 각각 다음 3가지 요소를 포함해야 한다.

   - (근거) 인사이트를 뒷받침하는 수치/그래프 1개 이상
   - (실행) 제안 액션의 대상 세그먼트 + 실행 방법 + 기대 효과
   - (검증) "추가로 필요한 데이터" 또는 "반증 가능성" 1문장

5. 보너스 과제 (선택)

1. 이미지 고급 피처 추출

   - 이미지의 히스토그램 분포나 간단한 엣지 특성을 NumPy로 직접 계산하여 피처로 추가한다.
   - 이미지 데이터의 심층적인 수치화 방법을 경험한다.

2. 코호트 분석 (Cohort Analysis)

   - 가입 월별 고객의 재구매율(Retention Rate)을 계산하고 히트맵으로 시각화한다.
   - 시간에 따른 고객 행동 변화를 추적하는 분석 기법을 경험한다.

3. 인터랙티브 시각화

   - Plotly를 활용하여 RFM 세분화 결과를 인터랙티브 차트로 시각화한다. (이 보너스에 한하여 Plotly 사용 허용)
   - 동적 시각화의 장점을 경험한다.

개발환경

6. 개발 환경

- Python 3.8 이상
- 허용 라이브러리: NumPy, Pandas, Matplotlib, Seaborn
- 보너스 과제 3에 한하여 Plotly 사용을 예외적으로 허용한다.

제약조건

7. 제약 사항

금지 사항

- OpenCV, Pillow 등 이미지 처리 전용 라이브러리 사용 금지. NumPy 배열 연산으로 직접 구현한다.
- Scikit-learn, NLTK 등 머신러닝/자연어처리 라이브러리 사용 금지.
- 자동 EDA 라이브러리(pandas-profiling, sweetviz 등) 사용 금지.

이미지 처리 허용 범위 가이드

- 이미지 입력/변환 : imread() 사용 가능. 반환되는 NumPy 배열을 직접 조작한다.
- 저장/복구 : CSV에 배열이 문자열로 저장되는 경우fromstring() 또는 ast.literal_eval()로 복구한다.
- 리사이즈 : NumPy 슬라이싱(arr[::n, ::n])으로 단순 다운샘플링을 수행한다.

데이터셋

- Kaggle, AI Hub 등에서 이커머스/상품 관련 데이터를 수집하거나 제공된 샘플을 사용한다.
- 이미지 데이터는 NumPy 배열 형태로 변환하여 사용한다.
- 공개 라이선스(CC-BY, MIT 등) 데이터를 우선 사용하고, 출처를 반드시 명시한다.

Test case

8. 결과 예시

아래는 정답이 아니라 참고 예시다. 실제 문구와 구조는 달라도 된다.

- Class 구조 예시 :

```css
class DataAnalyzer:
    def __init__(self, data_path):
        self.df = None
        self.data_path = data_path
```

```
    def load_data(self):
        # 데이터 로드 로직
        pass

    def handle_missing_values(self, strategy='group_mean',
group_col=None):
        # 결측치 처리 로직
        pass

    def detect_outliers(self, column, threshold=1.5):
        # IQR 기반 이상치 탐지
        q1 = self.df[column].quantile(0.25)
        q3 = self.df[column].quantile(0.75)
        iqr = q3 - q1
        lower = q1 - threshold * iqr
        upper = q3 + threshold * iqr
        return self.df[(self.df[column] < lower) | (self.df[column] > upper)]

    def calculate_rfm(self, customer_col, date_col, amount_col):
        # RFM 점수 계산
        pass
```

- RFM 세분화 결과 예시 :

```
CSS
| 세그먼트 | 고객 수 | 평균 구매금액 | 특징 |
|---------|--------|-------------|------|
| VIP | 120 | 450,000원 | 최근 구매, 높은 빈도, 높은 금액 |
| Loyal | 350 | 180,000원 | 꾸준한 구매, 중간 금액 |
| New | 230 | 85,000원 | 최근 첫 구매, 낮은 빈도 |
| Churned | 300 | 120,000원 | 오래전 마지막 구매, 이탈 위험 |
```

- 인사이트 예시 :

```
CSS
[인사이트 1]
(근거) Churned 그룹이 전체 고객의 30%를 차지하며, 평균 이탈 기간은 90일
임.
(실행) Churned 대상 → 할인 쿠폰 발송 캠페인 → 재구매율 10% 향상 기대.
```

(검증) 이탈 원인(가격/품질/경쟁사)을 파악하려면 이탈 사유 설문 데이터가 추가로 필요함.

[인사이트 2]
(근거) VIP 그룹의 평균 구매 빈도는 월 4.2회로, 전체 매출의 45%를 차지함.
(실행) VIP 대상 → 전용 멤버십 혜택 강화 → 이탈 방지 전략 실행.
(검증) VIP 이탈 시 매출 감소 규모 시뮬레이션이 필요하며, 현재 데이터만으로는 정확한 LTV 산출이 어려움.

4. 평가자료

프로젝트 URL

https://github.com/giyeop-cody/codyssey-A1-1-mission

Branch명

main

5. 평가문항

항목 1

- src/pipeline.py 파일에 DataAnalyzer Class가 정의되어 있고, load_data(), handle_missing_values(), detect_outliers(), calculate_rfm() 메서드가 모두 포함되어 있는가?
- 노트북(notebooks/analysis_report.ipynb)이 처음부터 끝까지 에러 없이 실행되는가?
- 데이터셋이 1,000행 이상 / 8컬럼 이상이며, 수치형·범주형·날짜형·이미지(배열) 중 3종 이상의 데이터 타입을 포함하는가?
- 이미지 배열에서 추출한 Mean/Std 피처와 텍스트 파생 변수(단어 수 또는 문자열 길이)가 데이터프레임에 새로운 컬럼으로 추가되어 있는가?
- 이상치 처리 전후 분포 비교 시각화(박스플롯 등)가 포함되어 있는가?
- 히스토그램, 박스플롯, 막대그래프, 히트맵, 산점도, 라인차트 6종 시각화가 모두 존재하고, 각 차트에 제목과 축 레이블이 표기되어 있는가?
- 기술통계(평균/중앙값/표준편차/사분위수)와 상관분석(2쌍 이상) 결과가 제시되고, 각각에 수치 근거 + 시사점 해석이 작성되어 있는가?

PASS

FAIL

- RFM 분석 결과로 고객이 4개 이상 그룹으로 세분화되어 있으며, README.md에 비즈니스 인사이트가 3가지 이상 (근거 + 실행 + 검증) 형식으로 정리되어 있는가?

항목 2

- DataAnalyzer 클래스의 메서드를 왜 현재와 같이 분리했는지, 각 메서드의 책임과 역할을 설명할 수 있는가?
- 이미지 피처 추출 로직에서 Python for loop 대신 NumPy 배열 연산을 사용한 코드 부분을 직접 지목하고, 그렇게 구현한 설계 의도를 설명할 수 있는가? PASS
- 주요 파라미터(이상치 임계값, 결측치 대치 전략, RFM 기준일 등)를 하드코딩하지 않고 인자로 설계한 이유와, 이 설계가 다른 데이터셋 적용 시 어떤 이점을 주는지 설명할 수 있는가? FAIL
- 노트북의 마크다운 설명이 분석 단계별로 작성되어 있으며, 코드만으로는 파악하기 어려운 의사결정 (예: 대치 전략 선택 근거) 이 문서화되어 있는가?

항목 3

- IQR 방식의 이상치 탐지가 왜 필요한지, 어떤 데이터 분포에서 효과적이고 어떤 경우에 한계가 있는지(예: 정규분포 vs 비대칭 분포) 설명하고, 자신의 코드에서 해당 로직을 짚어 보여줄 수 있는가?
- 결측치를 그룹별 평균(또는 중앙값)으로 대치하는 이유와, 이 방식이 데이터 분포에 미치는 잠재적 위험(예: 분산 축소, 그룹 간 차이 과장)을 설명할 수 있는가? PASS
- RFM 점수 산정 기준(분위수 구간, 스코어링 방식)을 왜 그렇게 설정했는지, 세분화 결과가 비즈니스적으로 타당한 근거를 데이터에서 뽑아 설명할 수 있는가? FAIL
- NumPy 벡터 연산이 Python for loop보다 빠른 이유를 메모리 구조(연속 메모리 배치)와 연산 방식(SIMD 등) 관점에서 설명할 수 있는가?

항목 4

- 만약 고객 수가 100만 명으로 증가하고 이미지 해상도가 1024×1024로 커진다면, 현재 파이프라인에서 가장 먼저 병목이 발생하는 지점은 어디이며, 이를 어떻게 개선하겠는가?
- 이 RFM 분석 결과를 실제 마케팅 캠페인에 적용한다면, 가장 먼저 액션을 취해야 할 세그먼트는 어디이며 그 이유는 무엇인가? 해당 전략의 리스크와 이를 검증하기 위해 추가로 필요한 데이터는 무엇인가? PASS FAIL

- 이 분석 파이프라인을 머신러닝 예측 모델로 확장한다면, 어떤 타겟 변수(예: 이탈 여부, 구매 금액)를 설정하고 현재 파이프라인에서 생성한 피처 중 어떤 것을 활용하겠는가?

항목 5

보너스 문제 해결에 따른 크레딧 부여 ○ 부여 ○ 미부여

6. 평가결과

평가 시작일시: 2026-11-05 20:55

평가 결과: FAIL

FAIL

경험정도

○ 재구현 불가

평가 피드백

ⓘ 평가 피드백 등록을 완료하여야 평가 확정이 가능합니다.

내용

최소 100자 이상 입력해주세요 (현재 0자) 0 / 2000

평가 피드백 우수가이드 보기

목록 저장