분야 AI/SW 심화 구분 데이터 분석 학습시간 60시간 필수/선택 필수

쇼핑몰에서 누가 자주 오고 많이 사는지 분석해서 단골 찾기

문제기술

기술적 설명



1. 미션 소개

데이터 분석은 AI 모델링의 출발점이다. 아무리 정교한 알고리즘도 데이터를 제대로 이해하지 못하면 의미 있는 결과를 낼 수 없다. 실제 현업 데이터는 숫자, 텍스트, 범주, 이미지 등 다양한 형태가 뒤섞여 있으며, 이를 하나의 분석 흐름으로 통합하는 능력이 AI 엔지니어의 핵심 역량이다. 이 미션은 특정 산업에 국한되지 않는 도메인 공통 역량(멀티모달 전처리, 이상치 탐지, 파이프라인 모듈화, 고객 세분화)을 기르기 위해 설계되었다. 이커머스 데이터를 예시로 사용하지만, 여기서 익히는 기술은 에너지 분야(센서 수치 + 설비 이미지 + 수요 로그), 헬스케어 분야(바이탈 수치 + 의료 영상 메타데이터 + 진료 기록) 등 어떤 도메인에서도 동일한 패턴으로 전이된다. 이 미션에서는 이커머스 플랫폼의 상품 데이터를 분석한다. 상품명(텍스트), 가격(수치), 카테고리(범주), 등록일(날짜), 상품 이미지(배열) 등 서로 다른 유형의 멀티 모달 데이터를 다룬다. NumPy의 벡터 연산을 활용해 이미지 데이터를 직접 수치화하고, Pandas로 탐색적 데이터 분석(EDA)과 통계 분석을 수행하며, 시각화를 통해 비즈니스 인사이트를 도출하는 전 과정을 경험한다. 나아가 고객의 구매 패턴을 분석하는 RFM(Recency, Frequency, Monetary) 기법을 적용하여 고객을 세분화하고 비즈니스 전략을 제안하는 과정까지 수행한다. 이 경험은 이후 컴퓨터 비전, 자연어 처리, 머신러닝 미션에서 데이터 전처리와 특성 공학을 수행하기 위한 필수 기반이 된다.

이번 미션에서 반드시 수행하는 핵심 과제 3가지:

- 멀티 모달 데이터(수치 + 텍스트 + 이미지 배열)를 NumPy 벡터 연산으로 통합 처리하는 파이프라인을 Class로 구축한다.
- IQR 이상치 탐지, 그룹별 결측치 대치, 6종 시각화를 포함한 완전한 탐색적 데이터 분석(EDA)을 수행한다.

- RFM 분석으로 고객을 4개 이상 세그먼트로 분류하고, 데이터 근거에 기반한 비즈니스 전략을 제안한다.

2. 최종 결과물

다음 내용이 모두 포함된 **GitHub 레포지토리(Repository) URL**을 제출한다.

1. **데이터 분석 파이프라인 모듈** (src/pipeline.py)
    - 원본 데이터를 입력받아 전처리, 피처 엔지니어링, 요약 통계를 수행하는 Python Class 파일
    - 절차 지향 스크립트가 아닌 객체 지향(OOP) 구조로 설계
2. **분석 리포트 노트북** (notebooks/analysis_report.ipynb)
    - 전처리 결과 시각화, 통계 분석, RFM 기반 고객 세분화 결과 포함
    - 주요 분석 단계마다 마크다운 설명 작성
3. **README.md**
    - 프로젝트 개요, 데이터 설명, 비즈니스 인사이트 3가지 이상, 실행 방법

3. 과제 목표

이 과제를 마친 후, 학습자는 아래를 스스로 설명할 수 있어야 한다.

- NumPy의 벡터 연산(Vectorization)을 활용하여 반복문 없이 배열 데이터를 처리하는 방법을 설명할 수 있다.
- 이미지 데이터에서 평균, 표준편차 등 통계적 특성을 추출하여 수치형 피처로 변환하는 원리를 이해한다.
- IQR 방식을 활용한 이상치 탐지 로직을 직접 구현하고 그 원리를 설명할 수 있다.
- RFM 분석을 통해 고객을 세분화하고, 데이터 기반의 비즈니스 전략을 제안할 수 있다.
- 분석 로직을 Class로 구조화하여 재사용 가능한 코드를 설계하는 방법을 이해한다.

4. 기능 요구 사항

다음 요구사항을 모두 만족해야 한다.

1. 데이터 로드 및 기본 탐색
    - 최소 1,000건 이상, 8개 이상의 컬럼을 가진 이커머스 데이터셋을 사용한다.

- 수치형, 범주형, 날짜형, 이미지(배열) 중 최소 3가지 이상의 데이터 유형이 포함되어야 한다.
- info() , describe() , head() 를 활용하여 데이터 구조를 파악하고 마크다운으로 해석을 작성한다.
- RFM 계산용 거래 데이터는 최소 **customer_id**, **order_date**, **amount**(또는 price*qty) 컬럼을 포함해야 한다.
- Recency 기준일은 데이터의 최종 거래일(또는 분석 기준일)로 정의한다.
- 해석은 수치 근거 1개 이상 + 시사점 1문장 이상을 포함해야 한다.

2. 분석 파이프라인 모듈화 (OOP)

- 분석 로직을 DataAnalyzer 라는 Class로 구현한다.
- 최소 다음 메서드를 포함한다: load_data() , handle_missing_values() , detect_outliers() , calculate_rfm() .
- 주요 파라미터(예: 이상치 임계값, 결측치 대치 전략)는 메서드의 인자로 받도록 설계한다.

3. 멀티 모달 데이터 피처 엔지니어링

- 이미지 데이터 : NumPy를 활용하여 각 이미지의 평균(Mean)과 표준편차(Std)를 계산하고 새로운 컬럼으로 추가한다. 반복문(for loop) 대신 배열 연산을 사용한다.
- 텍스트 데이터 : 상품명에서 단어 수(Word Count) 또는 문자열 길이를 계산하여 파생 변수로 추가한다.

4. 결측치 및 이상치 처리

- 결측치 현황을 파악하고, 그룹별(GroupBy) 통계를 활용한 대치 로직을 1가지 이상 적용한다.
- IQR 방식의 이상치 탐지 로직을 직접 함수로 구현하고, 처리 전후의 분포 변화를 시각화한다.

5. 통계 분석

- 주요 수치형 변수에 대해 평균, 중앙값, 표준편차, 사분위수를 계산하고 해석한다.
- 최소 2쌍 이상의 변수에 대해 상관계수를 계산하고 해석한다.
- 모든 해석은 수치 근거 1개 이상을 포함하고 시사점 1문장 이상을 기술한다.

6. 시각화

- 다음 6가지 유형의 차트를 각각 1개 이상 작성한다.
  - 히스토그램 : 수치형 변수의 분포
  - 박스플롯 : 이상치 처리 전후 비교

    - 막대그래프 : 범주형 변수의 빈도 또는 RFM 세그먼트별 고객 수
    - 히트맵 : 상관행렬 또는 RFM 세그먼트 분포
    - 산점도 : 두 수치형 변수의 관계
    - 라인차트 : 시계열 추세 (예: 월별 매출 추이)
- 모든 차트에는 제목과 축 레이블을 포함한다.

7. RFM 기반 고객 세분화

- 거래 데이터를 바탕으로 고객별 Recency, Frequency, Monetary 점수를 계산한다.
- 고객을 최소 4개 그룹(예: VIP, Loyal, New, Churned)으로 세분화하고 각 그룹의 특징을 분석한다.
- 세분화 결과를 바탕으로 비즈니스 관점의 인사이트를 README.md에 정리한다.

8. README.md에 작성하는 비즈니스 인사이트는 각각 다음 3가지 요소를 포함해야 한다.

- (근거) 인사이트를 뒷받침하는 수치/그래프 1개 이상
- (실행) 제안 액션의 대상 세그먼트 + 실행 방법 + 기대 효과
- (검증) "추가로 필요한 데이터" 또는 "반증 가능성" 1문장

5. 보너스 과제 (선택)

1. 이미지 고급 피처 추출

- 이미지의 히스토그램 분포나 간단한 엣지 특성을 NumPy로 직접 계산하여 피처로 추가한다.
- 이미지 데이터의 심층적인 수치화 방법을 경험한다.

2. 코호트 분석 (Cohort Analysis)

- 가입 월별 고객의 재구매율(Retention Rate)을 계산하고 히트맵으로 시각화한다.
- 시간에 따른 고객 행동 변화를 추적하는 분석 기법을 경험한다.

3. 인터랙티브 시각화

- Plotly를 활용하여 RFM 세분화 결과를 인터랙티브 차트로 시각화한다. (이 보너스에 한하여 Plotly 사용 허용)
- 동적 시각화의 장점을 경험한다.

개발환경

6. 개발 환경

- Python 3.8 이상
- 허용 라이브러리: NumPy, Pandas, Matplotlib, Seaborn
- 보너스 과제 3에 한하여 Plotly 사용을 예외적으로 허용한다.

제약조건

7. 제약 사항

금지 사항

- OpenCV, Pillow 등 이미지 처리 전용 라이브러리 사용 금지. NumPy 배열 연산으로 직접 구현한다.
- Scikit-learn, NLTK 등 머신러닝/자연어처리 라이브러리 사용 금지.
- 자동 EDA 라이브러리(pandas-profiling, sweetviz 등) 사용 금지.

이미지 처리 허용 범위 가이드

- 이미지 입력/변환 : imread() 사용 가능. 반환되는 NumPy 배열을 직접 조작한다.
- 저장/복구 : CSV에 배열이 문자열로 저장되는 경우fromstring() 또는 ast.literal_eval()로 복구한다.
- 리사이즈 : NumPy 슬라이싱(arr[::n, ::n])으로 단순 다운샘플링을 수행한다.

데이터셋

- Kaggle, AI Hub 등에서 이커머스/상품 관련 데이터를 수집하거나 제공된 샘플을 사용한다.
- 이미지 데이터는 NumPy 배열 형태로 변환하여 사용한다.
- 공개 라이선스(CC-BY, MIT 등) 데이터를 우선 사용하고, 출처를 반드시 명시한다.

Test Case

8. 결과 예시

아래는 정답이 아니라 참고 예시다. 실제 문구와 구조는 달라도 된다.

- Class 구조 예시 :

```
class DataAnalyzer:
    def __init__(self, data_path):
        self.df = None
        self.data_path = data_path

    def load_data(self):
        # 데이터 로드 로직
        pass

    def handle_missing_values(self, strategy='group_mean', group_col=None):
        # 결측치 처리 로직
        pass

    def detect_outliers(self, column, threshold=1.5):
        # IQR 기반 이상치 탐지
        q1 = self.df[column].quantile(0.25)
        q3 = self.df[column].quantile(0.75)
        iqr = q3 - q1
        lower = q1 - threshold * iqr
        upper = q3 + threshold * iqr
        return self.df[(self.df[column] < lower) | (self.df[column] > upper)]

    def calculate_rfm(self, customer_col, date_col, amount_col):
        # RFM 점수 계산
        pass
```

- RFM 세분화 결과 예시 :

```
| 세그먼트 | 고객 수 | 평균 구매금액 | 특징 |
|---------|--------|-------------|------|
| VIP | 120 | 450,000원 | 최근 구매, 높은 빈도, 높은 금액 |
| Loyal | 350 | 180,000원 | 꾸준한 구매, 중간 금액 |
| New | 230 | 85,000원 | 최근 첫 구매, 낮은 빈도 |
| Churned | 300 | 120,000원 | 오래전 마지막 구매, 이탈 위험 |
```

- 인사이트 예시 :

> [인사이트 1]
> (근거) Churned 그룹이 전체 고객의 30%를 차지하며, 평균 이탈 기간은 90일임.
> (실행) Churned 대상 → 할인 쿠폰 발송 캠페인 → 재구매율 10% 향상 기대.
> (검증) 이탈 원인(가격/품질/경쟁사)을 파악하려면 이탈 사유 설문 데이터가 추가로 필요함.
>
> [인사이트 2]
> (근거) VIP 그룹의 평균 구매 빈도는 월 4.2회로, 전체 매출의 45%를 차지함.
> (실행) VIP 대상 → 전용 멤버십 혜택 강화 → 이탈 방지 전략 실행.
> (검증) VIP 이탈 시 매출 감소 규모 시뮬레이션이 필요하며, 현재 데이터만으로는 정확한 LTV 산출이 어려움.